异常检测算法之(KNN)-K Nearest Neighbors

小伍哥聊风控
风控算法、风控策略，反欺诈，异常检测，复杂网络挖掘、风控转行

关注他

大家好，我是小伍哥。

之前写了一个很长的关于KNN的文章，估计很多人都没时间看，把里面关于风控部分拆分出来，方便大家阅读，并且做了一个细化，加了更多的细节进去。

sklearn库里的KNN并没有直接用于异常检测，但是包含了距离计算的函数，所以我们应用PyOD中KNN库进行异常检测，里面基本上也是调用sklearn的函数进行计算，并进行了一些加工。

一、图解KNN异常检算法

KNN怎么进行无监督检测呢，其实也是很简单的，异常点是指远离大部分正常点的样本点，再直白点说，**异常点一定是跟大部分的样本点都隔得很远**。基于这个思想，我们只需要**依次计算每个样本点与它最近的K个样本的平均距离**，再利用计算的距离与阈值进行比较，如果大于阈值，则认为是异常点，同样，为了帮助读者理解如何利用KNN思想，实现异常值的识别，我画了下面这张图。对于第一个，3个邻居的平均距离为（2+2+3）/3=2.33，对于第二点，3个邻居的平均距离为（7+8+5）/3=6.667，明显，第二个点的异常程度要高与第一个点。当然，这里除了平均距离，还可以用中位数，也可以用最大距离，通过method这个参数进行控制。

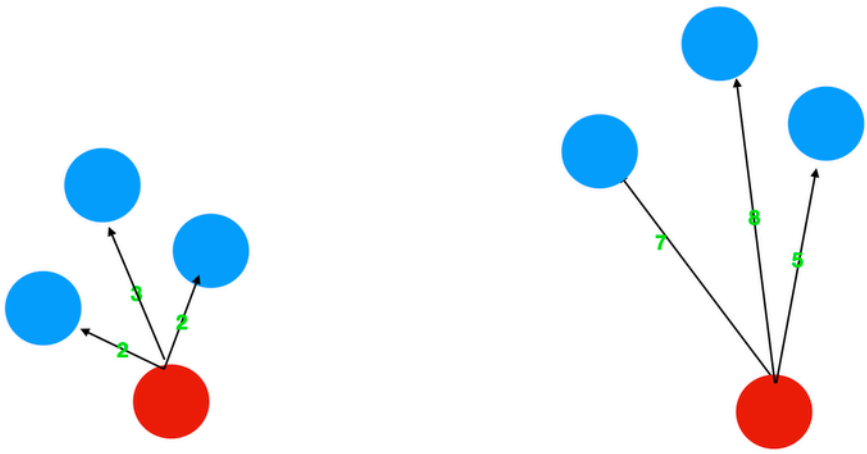

优点是不需要假设数据的分布，**缺点是**不适合高维数据、只能找出异常点，无法找出异常簇、你每一次计算近邻距离都需要遍历整个数据集，不适合大数据及在线应用、有人用hyper-grid技术提速将KNN应用到在线情况，但是还不是足够快，仅可以找出全局异常点，无法找到局部异常点。

KNN异常检测过程：对未知类别的数据集中的每个点依次执行以下操作：

1) 计算当前点 与 数据集中每个点的距离

2) 按照距离递增次序排序

3) 选取与当前点距离最小的k个点

4) 计算当前点与K个邻居的距离，并取均值、或者中值、最大值三个中的一个作为异常值

1、异常实例计算

无监督，我们就要标签去掉，为了演示过程，我们引进了9号嘉宾，这个人非常自信，每一项都填的非常高，明显异常，我们的目的就是要把这种类似的异常的数据找出来。

序号	身高	颜值	财力	人品
0号	7	7	9	3
1号	5	4	5	6
2号	8	6	9	3
3号	9	9	7	7
4号	5	5	5	5
5号	9	9	9	1
6号	5	2	5	5
7号	8	8	7	6
9号	10	12	10	13

2、距离计算和排序

我们计算9号的异常程度，我们这里把计算和排序两步统一到一起了

先计算9号与其他样本的距离，然后排序，取最近的三个，我们计算平均距离，可以看到，9号与最近的三个邻居的平均距离是9.29

序号	身高	颜值	财力	人品	与9号的距离
6号	5	2	5	5	14.63
1号	5	4	5	6	12.77
4号	5	5	5	5	12.77
5号	9	9	9	1	12.45
2号	8	6	9	3	11.87
0号	7	7	9	3	11.62
7号	8	8	7	6	8.83
3号	9	9	7	7	7.42
9号	10	12	10	13	**9.29**

3、计算距离值

我们再计算4号嘉宾的距离，可以看到，最近的三个邻居与4号的平均距离为3.07，只是9号的三分之一，相对来说就比较正常了。当然距离计算可以用最大值，平均值，中位数三个，算法中通过**method**这个参数进行调节。

序号	身高	颜值	财力	人品	与4号的距离
9号	10	12	10	13	12.77
5号	9	9	9	1	8.00
3号	9	9	7	7	6.32
2号	8	6	9	3	5.48
0号	7	7	9	3	5.29
7号	8	8	7	6	4.80
6号	5	2	5	5	3.00
1号	5	4	5	6	1.41
4号	5	5	5	5	3.07

我们依次计算，就可以得到每个样本3个邻居的平均距离了，越高的越异常，我们也可以用Python的包来检测下我们计算的对不对。

```
import numpy as np
X_train = np.array([
[7,     7,      9,      3],
[5,     4,      5,      6],
[8,     6,      9,      3],
[9,     9,      7,      7],
[5,     5,      5,      5],
[9,     9,      9,      1],
[5,     2,      5,      5],
[8,     8,      7,      6],
[10,10, 12,     13]])
# import kNN分类器
from pyod.models.knn import KNN
```



```
clf = KNN( method='mean', n_neighbors=3, )
clf.fit(X_train)

# 返回训练数据X_train上的异常标签和异常分值
# 返回训练数据上的分类标签 (0: 正常值, 1: 异常值)
y_train_pred = clf.labels_
y_train_pred
array([0, 0, 0, 0, 0, 0, 0, 0, 1])

# 返回训练数据上的异常值（分值越大越异常）
y_train_scores = clf.decision_scores_
y_train_scores
array([2.91709951, 3.01181545, 3.09299219, 4.16692633, 3.07001503,
       4.25784112, 3.98142397, 3.24271326, 9.42068891])
```


我们自己计算的平均距离为9.29，系统算的9.42，有一点点的差异，可能是哪里加了一个微调的系数，大家可以探索下。

二、KNN异常检测算法应用

上面大概知道了KNN怎么进行异常检测的，现在我们找个具体的案例，看看更加明细的参数以及实现的过程，有个更加立体的感觉，并且学完能够应用起来。

源码地址：pyod.readthedocs.io/en/...

```
super(KNN, self).__init__(contamination=contamination)
self.n_neighbors = n_neighbors
self.method = method
self.radius = radius
self.algorithm = algorithm
self.leaf_size = leaf_size
self.metric = metric
self.p = p
self.metric_params = metric_params
self.n_jobs = n_jobs

if self.algorithm != 'auto' and self.algorithm != 'ball_tree':
    warn('algorithm parameter is deprecated and will be removed '
         'in version 0.7.6. By default, ball_tree will be used.',
         FutureWarning)

self.neigh_ = NearestNeighbors(n_neighbors=self.n_neighbors,
                               radius=self.radius,
                               algorithm=self.algorithm,
                               leaf_size=self.leaf_size,
                               metric=self.metric,
                               p=self.p,
                               metric_params=self.metric_params,
                               n_jobs=self.n_jobs,
                               **kwargs)
```

```
else:
    if self.metric_params is not None:
        self.tree_ = BallTree(X, leaf_size=self.leaf_size,
                              metric=self.metric,
                              **self.metric_params)
    else:
        self.tree_ = BallTree(X, leaf_size=self.leaf_size,
                              metric=self.metric)

dist_arr, _ = self.neigh_.kneighbors(n_neighbors=self.n_neighbors,
                                     return_distance=True)
dist = self._get_dist_by_method(dist_arr)

self.decision_scores_ = dist.ravel()
self._process_decision_scores()

return self
```

1、算法基本用法

地址：pyod.readthedocs.io/en/...

```
pyod.models.knn.KNN(contamination=0.1,
                    n_neighbors=5,
                    method='largest',
                    radius = 1.0,
                    algorithm='auto',
                    leaf_size=30,
                    metric='minkowski',
                    p=2,
                    metric_params=None,
                    n_jobs=1,
                    **kwargs)
```

2、参数详解

contamination：污染度,**contamination** : float in (0., 0.5), optional (default=0.1)数据集的污染量，即数据集中异常值的比例。在拟合时用于定义决策函数的阈值。如果是“自动”，则确定决策函数阈值，如原始论文中所示。*在版本0.20中更改：*默认值contamination将从0.20更改为'auto'0.22。

n_neighbors：选取相邻点数量

method：‘largest’、‘mean’、‘median’

- largest：使用与**第k个**相邻点的距离作为异常得分
- mean：使用**k个相邻点距离的平均值**作为异常得分
- median：使用**k个相邻点距离的中值**作为异常得分

radius : radius_neighbors使用的参数空间半径

algorithm：找到最近的k个样本

- kd_tree：依次对K维坐标轴，以中值切分，每一个节点是超矩形，适用于低维（<20时效率最高）
- ball_tree：以质心c和半径r分割样本空间，每一个节点是超球体，适用于高维（kd_tree高维效率低）
- brute：暴力搜索
- auto：通过 fit() 函数拟合，选择最适合的算法；如果数据稀疏，拟合后会自动选择brute，参数失效

leaf_size：**kd_tree和ball_tree中叶子大小**，影响构建、查询、存储，根据实际数据而定。树叶中可以有多于一个的数据点，算法在达到叶子时在其中执行暴力搜索即可。如果leaf size 趋向于 N（训练数据的样本数量），算法其实就是 brute force了。如果leaf size 太小了，趋向于1，那查询的时候 遍历树的时间就会大大增加。

metric：距离计算标准,距离标准图例

- euclidean：欧氏距离（p = 2）
- manhattan：曼哈顿距离（p = 1）
- minkowski：闵可夫斯基距离

p : metric参数，默认为2

metric_params : metric参数

n_jobs : 并行作业数，-1时，n_jobs为CPU核心数。

3、属性详解

decision_scores_：数据X上的异常打分，分数越高，则该数据点的异常程度越高

threshold_：异常样本的个数阈值，基于contamination这个参数的设置，总量最多等于n_samples * contamination

labels_: 数据X上的异常标签，返回值为二分类标签（0为正常点，1为异常点）

4、方法详解

fit(X): 用数据X来“训练/拟合”检测器clf。即在初始化检测器clf后，用X来“训练”它。

fit_predict_score(X, y): 用数据X来训练检测器clf，并预测X的预测值，并在真实标签y上进行评估。此处的y只是用于评估，而非训练

decision_function(X): 在检测器clf被fit后，可以通过该函数来预测未知数据的异常程度，返回值为原始分数，并非0和1。返回分数越高，则该数据点的异常程度越高

predict(X): 在检测器clf被fit后，可以通过该函数来预测未知数据的异常标签，返回值为二分类标签（0为正常点，1为异常点）

predict_proba(X): 在检测器clf被fit后，预测未知数据的异常概率，返回该点是异常点概率

当检测器clf被初始化且fit(X)函数被执行后，clf就会生成两个重要的属性：

decision_scores: 数据X上的异常打分，分数越高，则该数据点的异常程度越高

5、案例分析

KNN算法专注于全局异常检测，所以无法检测到局部异常。首先，对于数据集中的每条记录，必须找到k个最近的邻居。然后使用这K个邻居计算异常分数。**最 大：**使用到第k个邻居的距离作为离群值得分；**平均值：**使用所有k个邻居的平均值作为离群值得分；**中位数：**使用到k个邻居的距离的中值作为离群值得分

在实际方法中**后两种**的应用度较高。然而，分数的绝对值在很大程度上取决于数据集本身、维度数和规范化。参数k的选择当然对结果很重要。如果选择过低，记录的密度估计可能不可靠。（即过拟合）另一方面，如果它太大，密度估计可能太粗略。K值的选择通常在10-50这个范围内。所以在分类方法中，选择一个合适的K值，可以用交叉验证法。

```
#导入
from pyod.models.knn import KNN
from pyod.utils.data import generate_data
from pyod.utils.data import evaluate_print
from pyod.utils.example import visualize

#参数设置
contamination = 0.1  # percentage of outliers
n_train = 200  # number of training points
n_test = 100  # number of testing points

# 数据生成
X_train, y_train, X_test, y_test = generate_data(\
    n_train=n_train, n_test=n_test,\
    contamination=contamination)

# import kNN分类器
from pyod.models.knn import KNN

# 训练一个kNN检测器 初始化检测器clf
clf_name = 'kNN'
clf = KNN()
# 使用X_train训练检测器clf
clf.fit(X_train)

# 返回训练数据X_train上的异常标签和异常分值
# 返回训练数据上的分类标签 (0: 正常值, 1: 异常值)
y_train_pred = clf.labels_

# 返回训练数据上的异常值（分值越大越异常）
y_train_scores = clf.decision_scores_

# 用训练好的clf来预测未知数据中的异常值
y_test_pred   = clf.predict(X_test)
y_test_scores = clf.decision_function(X_test)
```

对识别结果可视化

```
# 模型可视化
visualize(clf_name,
          X_train,
```

```
    y_train,
    X_test,
    y_test,
    y_train_pred,
    y_test_pred,
    show_figure=True,
    save_figure=False
)
```

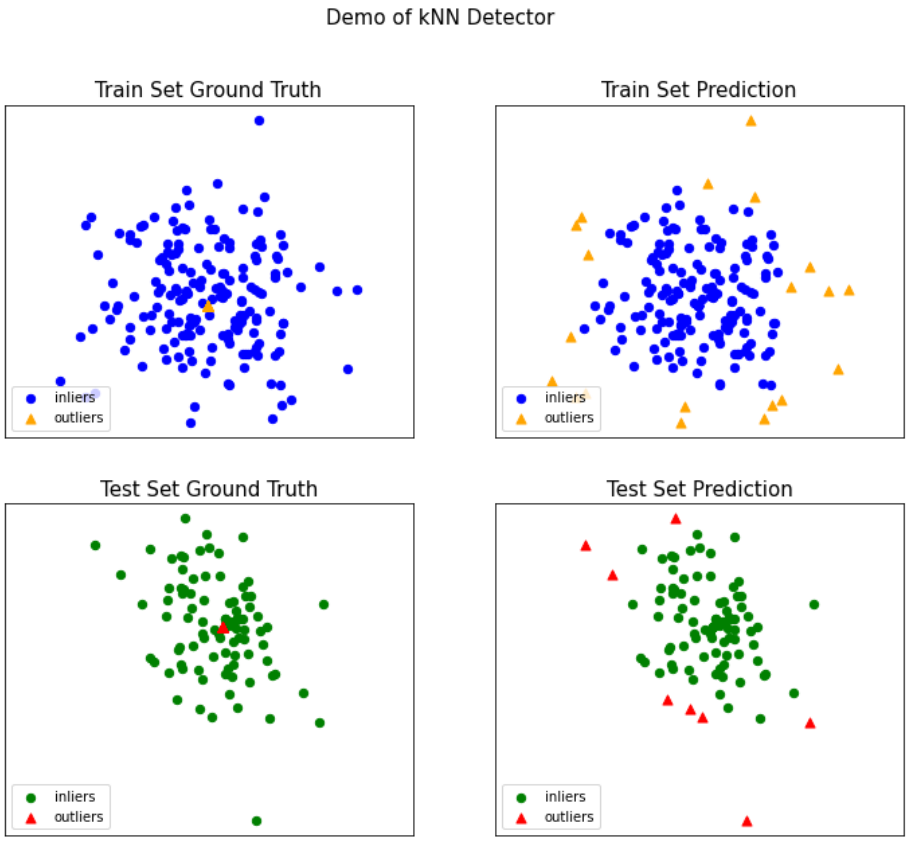

发布于 2022-04-20 11:27

异常检测　工程检测　大数据风控

6 条评论 默认 最新

江小北
最后一张图的真实值和预测差距很大啊
05-03 回复 喜欢

禹天
大佬，你的代码报了这个错“Expected 2D array, got 1D array instead”
2022-10-06 回复 喜欢

loki
学习一下
2022-06-13 回复 喜欢

ohhyohyo
来看了
2022-04-20 回复 喜欢

小伍哥聊风控 作者
有点长
2022-04-20 回复 喜欢

小伍哥聊风控 作者
🤭🤭🤭
2022-04-20 回复 喜欢

文章被以下专栏收录

风控策略算法
风控相关策略算法文章分享

推荐阅读

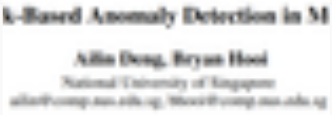

[论文阅读]用GNN来做时序异常检测
芝士确实是热量

[译]使用图神经网络(GNN)寻找最短路径
本文使用 Zhihu On VSCode 创作并发布转载于：https://yqfile.alicdn.com/c32ad5... 译者：ZelinZang, zelinzang@gmail.com, https://www.zhihu.com/pe...
臧泽林

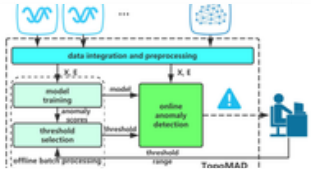

AIOPS笔记：GNN在异常检测上的应用论文（一）
路人Y 发表于AIOPS...

Mask-RCNN缺陷检自己的数据集
Isabe... 发