



【机器学习】支持向量机 SVM（非常详细）



阿泽
复旦大学 计算机技术硕士

关注他

创作声明：内容包含虚构创作


6,568 人赞同了该文章

SVM 是一个非常优雅的算法，具有完善的数学理论，虽然如今工业界用到的不多，但还是决定花点时间去写篇文章整理一下。

1. 支持向量

1.1 线性可分

首先我们先来了解下什么是线性可分。



在二维空间上，两类点被一条直线完全分开叫做线性可分。

严格的数学定义是：

D_0 和 D_1 是 n 维欧氏空间中的两个点集。如果存在 n 维向量 w 和实数 b ，使得所有属于 D_0 的点 x_i 都有 $w x_i + b > 0$ ，而对于所有属于 D_1 的点 x_j 则有 $w x_j + b < 0$ ，则我们称 D_0 和 D_1 线性可分。


1.2 最大间隔超平面

从二维扩展到多维空间中时，将 D_0 和 D_1 完全正确地划分开的 $w x + b = 0$ 就成了一个超平面。

为了使这个超平面更具鲁棒性，我们会去找最佳超平面，以最大间隔把两类样本分开的超平面，也称之为最大间隔超平面。

- 两类样本分别分割在该超平面的两侧；
- 两侧距离超平面最近的样本点到超平面的距离被最大化了。

1.3 支持向量



样本中距离超平面最近的一些点，这些点叫做支持向量。

1.4 SVM 最优化问题

SVM 想要的就是找到各类样本点到超平面的距离最远，也就是找到最大间隔超平面。任意超平

面可以用下面这个线性方程来描述：

$$x = (x_1, x_2, \dots, x_d)^T$$

$$w = (w_1, w_2, \dots, w_d)^T$$

$$w^T x + b = 0$$

法向量

x: 平面上的点
w: 平面上的法向量, 决定超平面的方向
b: 是一个实数, 表示超平面离原点的距离
w和x都是n维向量

二维空间点 (x, y) 到直线 $Ax + By + C = 0$ 的距离公式是：


$$\frac{|Ax + By + C|}{\sqrt{A^2 + B^2}}$$

扩展到 n 维空间后, 点 $x = (x_1, x_2 \dots x_n)$ 到直线 $w^T x + b = 0$ 的距离为：

$$\frac{|w^T x + b|}{\|w\|}$$

其中 $\|w\| = \sqrt{w_1^2 + \dots w_n^2}$ 。

如图所示, 根据支持向量的定义我们知道, 支持向量到超平面的距离为 d, 其他点到超平面的距离大于 d。



于是我们有这样的一个公式：

$$\begin{cases} \frac{w^T x + b}{\|w\|} \geq d & y = 1 \\ \frac{w^T x + b}{\|w\|} \leq -d & y = -1 \end{cases}$$

稍作转化可以得到：

$$\begin{cases} \frac{w^T x + b}{\|w\|d} \geq 1 & y = 1 \\ \frac{w^T x + b}{\|w\|d} \leq -1 & y = -1 \end{cases}$$


$\|w\|d$ 是正数, 我们暂且令它为 1 (之所以令它等于 1, 是为了方便推导和优化, 且这样做对目标函数的优化没有影响), 故：

$$\begin{cases} w^T x + b \geq 1 & y = 1 \\ w^T x + b \leq -1 & y = -1 \end{cases}$$

将两个方程合并，我们可以简写为：

$$y(w^T x + b) \geq 1$$

至此我们就可以得到最大间隔超平面的上下两个超平面：



每个支持向量到超平面的距离可以写为：

$$d = \frac{|w^T x + b|}{\|w\|}$$

由上述 $y(w^T x + b) > 1 > 0$ 可以得到 $y(w^T x + b) = |w^T x + b|$ ，所以我们得到：

$$d = \frac{y(w^T x + b)}{\|w\|}$$

最大化这个距离：

$$\max 2 * \frac{y(w^T x + b)}{\|w\|}$$

这里乘上 2 倍也是为了后面推导，对目标函数没有影响。刚刚我们得到支持向量 $y(w^T x + b) = 1$ ，所以我们得到：

$$\max \frac{2}{\|w\|}$$

再做一个转换：

$$\min \frac{1}{2} \|w\|^2$$

为了方便计算（去除 $\|w\|$ 的根号），我们有：

$$\min \frac{1}{2} \|w\|^2$$

所以得到的最优化问题是：

$$\min \frac{1}{2} \|w\|^2 \text{ s.t. } y_i (w^T x_i + b) \geq 1$$

2. 对偶问题

2.1 拉格朗日乘数法

2.1.1 等式约束优化问题

本科高等数学学的拉格朗日乘数法是等式约束优化问题：

$$\begin{aligned} \min f(x_1, x_2, \dots, x_n) \\ s.t. \quad h_k(x_1, x_2, \dots, x_n) = 0 \quad k = 1, 2, \dots, l \end{aligned}$$

我们令 $L(x, \lambda) = f(x) + \sum_{k=1}^l \lambda_k h_k(x)$ ，函数 $L(x, y)$ 称为 Lagrange 函数，参数 λ 称为 Lagrange 乘子没有非负要求。

利用必要条件找到可能的极值点：


$$\begin{cases} \frac{\partial L}{\partial x_i} = 0 & i = 1, 2, \dots, n \\ \frac{\partial L}{\partial \lambda_k} = 0 & k = 1, 2, \dots, l \end{cases}$$

具体是否为极值点需根据问题本身的具体情况检验。这个方程组称为等式约束的极值必要条件。

等式约束下的 Lagrange 乘数法引入了 l 个 Lagrange 乘子，我们将 x_i 与 λ_k 一视同仁，把 λ_k 也看作优化变量，共有 $(n + l)$ 个优化变量。

2.1.2 不等式约束优化问题

而我们现在面对的是不等式优化问题，针对这种情况其主要思想是将不等式约束条件转变为等式约束条件，引入松弛变量，将松弛变量也是为优化变量。



知乎 @是泽哥啊

以我们的例子为例：

$$\begin{aligned} \min f(w) = \min \frac{1}{2} \|w\|^2 \\ s.t. \quad g_i(w) = 1 - y_i(w^T x_i + b) \leq 0 \end{aligned}$$

我们引入松弛变量 a_i^2 得到 $h_i(w, a_i) = g_i(w) + a_i^2 = 0$ 。这里加平方主要为了不再引入新的约束条件，如果只引入 a_i 那我们必须要保证 $a_i \geq 0$ 才能保证 $h_i(w, a_i) = 0$ ，这不符合我们的意愿。

由此我们将不等式约束转化为了等式约束，并得到 Lagrange 函数：

$$\begin{aligned}
 L(w, \lambda, a) &= f(w) + \sum_{i=1}^n \lambda_i h_i(w) \\
 &= f(w) + \sum_{i=1}^n \lambda_i [g_i(w) + a_i^2] \quad \lambda_i \geq 0
 \end{aligned}$$

由等式约束优化问题极值的必要条件对其求解，联立方程：

$$\begin{cases} \frac{\partial L}{\partial w_i} = \frac{\partial f}{\partial w_i} + \sum_{i=1}^n \lambda_i \frac{\partial g_i}{\partial w_i} = 0, \\ \frac{\partial L}{\partial a_i} = 2\lambda_i a_i = 0, \\ \frac{\partial L}{\partial \lambda_i} = g_i(w) + a_i^2 = 0, \\ \lambda_i \geq 0 \end{cases}$$

（为什么取 $\lambda_i \geq 0$ ，可以通过几何性质来解释，有兴趣的同学可以查下 KKT 的证明）。

针对 $\lambda_i a_i = 0$ 我们有两种情况：

情形一： $\lambda_i = 0, a_i \neq 0$

由于 $\lambda_i = 0$ ，因此约束条件 $g_i(w)$ 不起作用，且 $g_i(w) < 0$

情形二： $\lambda_i \neq 0, a_i = 0$

此时 $g_i(w) = 0$ 且 $\lambda_i > 0$ ，可以理解为约束条件 $g_i(w)$ 起作用了，且 $g_i(w) = 0$

综合可得： $\lambda_i g_i(w) = 0$ ，且在约束条件起作用时 $\lambda_i > 0, g_i(w) = 0$ ；约束不起作用时 $\lambda_i = 0, g_i(w) < 0$

由此方程组转换为：

$$\begin{cases} \frac{\partial L}{\partial w_i} = \frac{\partial f}{\partial w_i} + \sum_{j=1}^n \lambda_j \frac{\partial g_j}{\partial w_i} = 0, \\ \lambda_i g_i(w) = 0, \\ g_i(w) \leq 0 \\ \lambda_i \geq 0 \end{cases}$$

以上便是不等式约束优化问题的 KKT(Karush-Kuhn-Tucker) 条件， λ_i 称为 KKT 乘子。

这个式子告诉了我们什么事情呢？

直观来讲就是，支持向量 $g_i(w) = 0$ ，所以 $\lambda_i > 0$ 即可。而其他向量 $g_i(w) < 0, \lambda_i = 0$ 。

我们原本问题时要求： $\min \frac{1}{2} \|w\|^2$ ，即求 $\min L(w, \lambda, a)$

$$\begin{aligned}
 L(w, \lambda, a) &= f(w) + \sum_{i=1}^n \lambda_i [g_i(w) + a_i^2] \\
 &= f(w) + \sum_{i=1}^n \lambda_i g_i(w) + \sum_{i=1}^n \lambda_i a_i^2
 \end{aligned}$$

由于 $\sum_{i=1}^n \lambda_i a_i^2 \geq 0$ ，故我们将问题转换为： $\min L(w, \lambda)$ ：

$$L(w, \lambda) = f(w) + \sum_{i=1}^n \lambda_i g_i(w)$$

假设找到了最佳参数是的目标函数取得了最小值 p。即 $\frac{1}{2} \|w\|^2 = p$ 。而根据 $\lambda_i \geq 0$ ，可知 $\sum_{i=1}^n \lambda_i g_i(w) \leq 0$ ，因此 $L(w, \lambda) \leq p$ ，为了找到最优的参数 λ ，使得 $L(w, \lambda)$ 接近 p，故问

题转换为求 $\max_{\lambda} L(w, \lambda)$ 。

故我们的最优化问题转换为：

$$\begin{aligned} \min_w \max_{\lambda} L(w, \lambda) \\ s.t. \quad \lambda_i \geq 0 \end{aligned}$$

出了上面的理解方式，我们还可以有另一种理解方式：由于 $\lambda_i \geq 0$ ，

$$\max_{\lambda} L(w, \lambda) = \begin{cases} \infty & g_i(w) \geq 0 \\ \frac{1}{2} \|w\|^2 & g_i(w) \leq 0 \end{cases}$$

所以 $\min(\infty, \frac{1}{2} \|w\|^2) = \frac{1}{2} \|w\|^2$ ，所以转化后的式子和原来的式子也是一样的。

2.2 强对偶性

对偶问题其实就是将：

$$\begin{aligned} \min_w \max_{\lambda} L(w, \lambda) \\ s.t. \quad \lambda_i \geq 0 \end{aligned}$$

变成了：

$$\begin{aligned} \max_{\lambda} \min_w L(w, \lambda) \\ s.t. \quad \lambda_i \geq 0 \end{aligned}$$

假设有个函数 f 我们有：

$$\min \max f \geq \max \min f$$

也就是说，最大的里面挑出来的最小的也要比最小的里面挑出来的最大的要大。这关系实际上就是弱对偶关系，而强对偶关系是当等号成立时，即：

$$\min \max f = \max \min f$$

如果 f 是凸优化问题，强对偶性成立。而我们之前求的 KKT 条件是强对偶性的充要条件。

3. SVM 优化

我们已知 SVM 优化的主问题是：

$$\begin{aligned} \min_w \frac{1}{2} \|w\|^2 \\ s.t. \quad g_i(w, b) = 1 - y_i (w^T x_i + b) \leq 0, \quad i = 1, 2, \dots, n \end{aligned}$$

那么求解线性可分的 SVM 的步骤为：

步骤 1：

构造拉格朗日函数：

$$\begin{aligned} \min_{w, b} \max_{\lambda} L(w, b, \lambda) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \lambda_i [1 - y_i (w^T x_i + b)] \\ s.t. \quad \lambda_i \geq 0 \end{aligned}$$

步骤 2:

利用强对偶性转化:

$$\max_{\lambda} \min_{w, b} L(w, b, \lambda)$$

现对参数 w 和 b 求偏导数:

$$\begin{aligned}\frac{\partial L}{\partial w} &= w - \sum_{i=1}^n \lambda_i x_i y_i = 0 \\ \frac{\partial L}{\partial b} &= \sum_{i=1}^n \lambda_i y_i = 0\end{aligned}$$

得到:

$$\begin{aligned}\sum_{i=1}^n \lambda_i x_i y_i &= w \\ \sum_{i=1}^n \lambda_i y_i &= 0\end{aligned}$$

我们将这个结果带回到函数中可得:

$$\begin{aligned}L(w, b, \lambda) &= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \lambda_i - \sum_{i=1}^n \lambda_i y_i \left(\sum_{j=1}^n \lambda_j y_j (x_i \cdot x_j) + b \right) \\ &= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \lambda_i - \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^n \lambda_i y_i b \\ &= \sum_{j=1}^n \lambda_j - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j)\end{aligned}$$

也就是说:

$$\min_{w, b} L(w, b, \lambda) = \sum_{j=1}^n \lambda_j - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j)$$

步骤 3:

由步骤 2 得:

$$\begin{aligned}\max_{\lambda} & \left[\sum_{j=1}^n \lambda_j - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) \right] \\ s. t. & \quad \sum_{i=1}^n \lambda_i y_i = 0 \quad \lambda_i \geq 0\end{aligned}$$

我们可以看出来这是一个二次规划问题, 问题规模正比于训练样本数, 我们常用 SMO(Sequential Minimal Optimization) 算法求解。

SMO(Sequential Minimal Optimization), 序列最小优化算法, 其核心思想非常简单: 每次只优化一个参数, 其他参数先固定住, 仅求当前这个优化参数的极值。我们来看一下 SMO 算法在 SVM 中的应用。

我们刚说了 SMO 算法每次只优化一个参数, 但我们的优化目标有约束条件: $\sum_{i=1}^n \lambda_i y_i = 0$, 没法一次只变动一个参数。所以我们选择了一次选择两个参数。具体步骤为:

1. 选择两个需要更新的参数 λ_i 和 λ_j , 固定其他参数。于是我们有以下约束:

这样约束就变成了:

$$\lambda_i y_i + \lambda_j y_j = c \quad \lambda_i \geq 0, \lambda_j \geq 0$$

其中 $c = -\sum_{k \neq i, j} \lambda_k y_k$ ，由此可以得出 $\lambda_j = \frac{c - \lambda_i y_i}{y_j}$ ，也就是说我们可以用 λ_i 的表达式代替 λ_j 。这样就相当于把目标问题转化成了仅有一个约束条件的最优化问题，仅有的约束是 $\lambda_i \geq 0$ 。

2. 对于仅有一个约束条件的最优化问题，我们完全可以在 λ_i 上对优化目标求偏导，令导数为零，从而求出变量值 $\lambda_{i_{new}}$ ，然后根据 $\lambda_{i_{new}}$ 求出 $\lambda_{j_{new}}$ 。

3. 多次迭代直至收敛。

通过 SMO 求得最优解 λ^* 。

步骤 4：

我们求偏导数时得到：

$$w = \sum_{i=1}^m \lambda_i y_i x_i$$

由上式可求得 w 。

我们知道所有 $\lambda_i > 0$ 对应的点都是支持向量，我们可以随便找个支持向量，然后带入： $y_s(w x_s + b) = 1$ ，求出 b 即可，

两边同乘 y_s ，得 $y_s^2(w x_s + b) = y_s$

因为 $y_s^2 = 1$ ，所以： $b = y_s - w x_s$

为了更具鲁棒性，我们可以求得支持向量的均值：

$$b = \frac{1}{|S|} \sum_{s \in S} (y_s - w x_s)$$

步骤 5： w 和 b 都求出来了，我们就能构造出最大分割超平面： $w^T x + b = 0$

分类决策函数： $f(x) = \text{sign}(w^T x + b)$

其中 $\text{sign}(\cdot)$ 为阶跃函数：


$$\text{sign}(x) = \begin{cases} -1 & x < 0 \\ 0 & x = 0 \\ 1 & x > 0 \end{cases}$$

将新样本点导入到决策函数中既可得到样本的分类。


4. 软间隔

4.1 解决问题

在实际应用中，完全线性可分的样本是很少的，如果遇到了不能够完全线性可分的样本，我们应该怎么办？比如下面这个：




于是我们就有了软间隔，相比于硬间隔的苛刻条件，我们允许个别样本点出现在间隔带里面，比如：



我们允许部分样本点不满足约束条件：

$$1 - y_i(w^T x_i + b) \leq 0$$

为了度量这个间隔软到何种程度，我们为每个样本引入一个松弛变量 ξ_i ，令 $\xi_i \geq 0$ ，且 $1 - y_i(w^T x_i + b) - \xi_i \leq 0$ 。对应如下图所示：



4.2 优化目标及求解

增加软间隔后我们的优化目标变成了：

$$\min_{\{w\}} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i \quad \text{s.t.} \quad g_i(w, b) = 1 - y_i(w^T x_i + b) - \xi_i \leq 0, \quad \xi_i \geq 0, \quad i=1, 2, \dots, n$$

其中 C 是一个大于 0 的常数，可以理解为错误样本的惩罚程度，若 C 为无穷大， ξ_i 必然无穷小，如此一来线性 SVM 就又变成了线性可分 SVM；当 C 为有限值的时候，才会允许部分样本不遵循约束条件。

接下来我们将针对新的优化目标求解最优化问题：

步骤 1：

构造拉格朗日函数：

$$\min_{\{w, b, \xi\}} \max_{\{\lambda, \mu\}} L(w, b, \xi, \lambda, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^n \lambda_i [1 - \xi_i - y_i(w^T x_i + b)] - \sum_{i=1}^n \mu_i \xi_i \quad \text{s.t.} \quad \lambda_i \geq 0, \quad \mu_i \geq 0$$

其中 λ_i 和 μ_i 是拉格朗日乘子， w 、 b 和 ξ_i 是主问题参数。

根据强对偶性，将对偶问题转换为：

$$\max_{\{\lambda, \mu\}} \min_{\{w, b, \xi\}} L(w, b, \xi, \lambda, \mu)$$

步骤 2：

分别对主问题参数 w 、 b 和 ξ_i 求偏导数，并令偏导数为 0，得出如下关系：

$$w = \sum_{i=1}^m \lambda_i y_i x_i \quad 0 = \sum_{i=1}^m \lambda_i y_i \quad C = \lambda_i + \mu_i$$

将这些关系带入拉格朗日函数中，得到：

$$\min_{w,b,\lambda,\mu} L(w,b,\lambda,\mu) = \sum_{j=1}^n \lambda_j - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_j \lambda_j (x_i \cdot x_j) \parallel$$

最小化结果只有 λ 而没有 μ ，所以现在只需要最大化 λ 就好：

$$\max_{\lambda} \left[\sum_{j=1}^n \lambda_j - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_j \lambda_j (x_i \cdot x_j) \right] \text{ s.t. } \lambda_j \geq 0, \quad \sum_{j=1}^n \lambda_j = 0$$

我们可以看到这个和硬间隔的一样，只是多了个约束条件。

然后我们利用 SMO 算法求解得到拉格朗日乘子 λ^* 。

步骤 3：

$$w = \sum_{i=1}^m \lambda_i x_i \parallel b = \frac{1}{|S|} \sum_{s \in S} (y_s - w \cdot x_s)$$

然后通过上面两个式子求出 w 和 b ，最终求得超平面 $w^T x + b = 0$ ，

这边要注意一个问题，在间隔内的那部分样本点是不是支持向量？

我们可以由求参数 w 的那个式子可看出，只要 $\lambda_i > 0$ 的点都能够影响我们的超平面，因此都是支持向量。

5. 核函数

5.1 线性不可分

我们刚刚讨论的硬间隔和软间隔都是在说样本的完全线性可分或者大部分样本点的线性可分。

但我们可能会碰到的一种情况是样本点不是线性可分的，比如：

知乎

首发于
机器学习算法与自然语言处理

...



赞同 6568



分享

这种情况的解决方法就是：将二维线性不可分样本映射到高维空间中，让样本点在高维空间线性可分，比如：

对于在有限维度向量空间中线性不可分的样本，我们将其映射到更高维度的向量空间里，再通过间隔最大化的方式，学习得到支持向量机，就是非线性 SVM。

我们用 x 表示原来的样本点，用 $\phi(x)$ 表示 x 映射到特征新的特征空间后到新向量。那么分割超平面可以表示为： $f(x)=w \phi(x)+b$ 。

对于非线性 SVM 的对偶问题就变成了：

$$\min \lim_{\lambda} \left\{ \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (\phi(x_i) \cdot \phi(x_j)) - \sum_{j=1}^n \lambda_j \right\} \text{ s.t. } \sum_{i=1}^n \lambda_i y_i = 0, \quad \lambda_i \geq 0, \quad C - \lambda_i - \mu_i = 0$$

可以看到与线性 SVM 唯一的不同就是：之前的 $(x_i \cdot x_j)$ 变成了 $(\phi(x_i) \cdot \phi(x_j))$ 。

5.2 核函数的作用

我们不禁有个疑问：只是做个内积运算，为什么要有核函数的呢？

这是因为低维空间映射到高维空间后维度可能会很大，如果将全部样本的点乘全部计算好，这样的计算量太大了。

但如果我们有这样的一核函数 $k(x,y) = (\phi(x), \phi(y))$ ， x_i 与 x_j 在特征空间的内积等于它们在原始样本空间中通过函数 $k(x, y)$ 计算的结果，我们就不需要计算高维甚至无穷维空间的内积了。

举个例子：假设我们有一个多项式核函数：

$$k(x,y) = (x \cdot y + 1)^2$$

带进样本点的后：

$$k(x,y) = (\sum_{i=1}^n x_i \cdot y_i + 1)^2$$

而它的展开项是：

$$\sum_{i=1}^n x_i^2 y_i^2 + \sum_{i=1}^n \sum_{j=1}^{i-1} (\sqrt{2} x_{ij}) (\sqrt{2} y_{ij}) + \sum_{i=1}^n (\sqrt{2} x_i) (\sqrt{2} y_i) + 1$$

如果没有核函数，我们则需要把向量映射成：

$$x' = (x_1^2, \dots, x_n^2, \dots, \sqrt{2} x_1, \dots, \sqrt{2} x_n, 1)$$

然后在进行内积计算，才能与多项式核函数达到相同的效果。

可见核函数的引入一方面减少了我们计算量，另一方面也减少了我们存储数据的内存使用量。

5.3 常见核函数

我们常用核函数有：

线性核函数

$$k(x_i, x_j) = x_i^T x_j$$

多项式核函数

$$k(x_i, x_j) = (x_i^T x_j)^d$$

高斯核函数

$$k(x_i, x_j) = \exp(-\frac{\|x_i - x_j\|^2}{2\sigma^2})$$

这三个常用的核函数中只有高斯核函数是需要调参的。

6. 优缺点

6.1 优点

- 有严格的数学理论支持，可解释性强，不依靠统计方法，从而简化了通常的分类和回归问题；
- 能找出对任务至关重要的关键样本（即：支持向量）；
- 采用核技巧之后，可以处理非线性分类/回归任务；
- 最终决策函数只由少数的支持向量所确定，计算的复杂性取决于支持向量的数目，而不是样本空间的维数，这在某种意义上避免了“维数灾难”。

6.2 缺点

- 训练时间长。当采用 SMO 算法时，由于每次都需要挑选一对参数，因此时间复杂度为 $O(N^2)$ ，其中 N 为训练样本的数量；
- 当采用核技巧时，如果需要存储核矩阵，则空间复杂度为 $O(N^2)$ ；
- 模型预测时，预测时间与支持向量的个数成正比。当支持向量的数量较大时，预测计算复杂度较高。

因此支持向量机目前只适合小批量样本的任务，无法适应百万甚至上亿样本的任务。

7. 参考

1. 《机器学习》周志华
2. [最优化问题的KKT条件](#)
3. [一文理解拉格朗日对偶和KKT条件](#)
4. [支持向量机通俗导论（理解SVM的三层境界）](#)

欢迎关注我的公众号，第一时间追踪高质量学习笔记：阿泽的学习笔记。


阿泽的学习笔记

编辑于 2020-06-13 14:01

「敲公式不易，请作者喝杯咖啡。」

赞赏

8 人已赞赏



机器学习 SVM 监督学习



发布一条带图评论吧

204 条评论

默认 最新



brunch

核函数不好选，还是得炼丹

2019-08-13

回复 45



阿泽 作者

一般选择线性核函数，效果不好上高斯核函数，高斯核函数可以映射到无限维空间

2019-08-13

回复 42



TechGuide 阿泽

我在csdn也更新了几篇关于svm的文章，欢迎作者指正
blog.csdn.net/weixin_41...

2020-04-08

回复 10

展开其他 2 条回复 >



JoeYang

前面已经假设 $wd=1$ 了 后面为啥还要推半天得到 $d=1/w$ 直接用 $wd=1$ 不就可以得到了吗

2020-05-16

回复 19



笑呵呵

我也在想这个问题，请问您想通了嘛

2020-05-29

回复 5



肆十叁 阿滴

这是尺度问题，对优化结果没有任何影响

2021-09-19

回复 3

查看全部 13 条回复 >

- 

徐志国

...

$\|w\|d$ 是正数，我们暂且令它为 1，这个时候就可以得出 $d = 1/\|w\|$ ，还用得着后面的啰哩啰嗦吗？

2020-10-28

回复 17
- 

djdxkcjcjc

...

数学部分写的极其混乱，其他的还可以

2021-04-28

回复 15
- 

又又

...

统计魅力真大（我要努力学习）

2019-08-30

回复 11
- 

Yuyang

...

一直不理解为什么需要用强对偶转化啊，是原来的minimax不好解吗

2019-09-04

回复 11
- 

阿泽

作者

...

这个问题非常好，主要有两点吧：
max 是针对 λ 的，而 min 是针对 w, b 的，通过对偶可以化简 去除 w 和 b 。并不是一定要用对偶，只是用了可以简化问题复杂度，本来是和样本维度 w 和样本数量 n 有关的，现在化简后 w, b 就没有了，只和样本数量有关；
通过对偶转化简后引入了核函数，解决了映射到高维的巨额计算量。

2019-09-04

回复 44
- 

皮卡丘

...

参数 w 向量的L2正则是一个凸函数，求解最小值相对简单

2020-04-29

回复 1
- 

我能否将你比成夏

...

有的证明不严谨

2020-10-15

回复 10
- 

真的不爱吃青椒

...

CSDN上这篇也讲的不错，而且用到的高数知识都从头讲了一遍，不用回去翻书了🤔
blog.csdn.net/weixin_44...

2021-10-25

回复 12
- 

小小梦想

...

可以看看这篇:mp.weixin.qq.com/s/tj_O...

2021-10-06

回复 3
- 

炒方便面阿

...

为什么因为 $\lambda * a$ 大于等于0 就可以把这项去掉？

2020-04-17

回复 8
- 

肆十叁

机器学习机器学习

...

对 a 求偏导，能得到一个与权值无关的值为0的式子，就是 $\lambda * a$

2021-09-19

回复 喜欢
- 

机器学习机器学习

...

同问

2021-07-02

回复 喜欢
- 展开其他 3 条回复 >
- 

戏戏知了

...

还是没有看懂啊，还有没有更通俗的啊

2020-09-23

回复 5
- 

陈俊柏

...

为什么“由于 $\sum |a_i|^2 \geq 0$ ”可以将问题转换为“ $\min L(w, \lambda)$ ”

2020-08-27

回复 5
- 

Joker

...

同问。感觉这篇写的逻辑有点问题。引入的松弛变量有些多余，且证明过程中多处推导都不通顺。

2021-07-02

回复 3



farseertao

我也觉得有问题，目标函数min不等价于拉格朗日min，最多是拉格朗日函数偏导=0

2022-02-18

回复 1



中原人皆为奴

差评，写的逻辑不清，错误多

2022-02-06

回复 4



文云博士

支持向量机（Support Vector Machine, SVM）是一种监督学习算法，常用于分类和回归问题。它的基本思想是在训练数据集中找到一个超平面，使得超平面尽可能地将不同类别的数据分开，同时尽量缩小超平面与数据点之间的间隔。

在分类问题中，支持向量机通常使用线性分类器，即找到一个超平面使得其将数据点分为两个类别。在非线性分类问题中，支持向量机可以通过将数据映射到高维空间，再在高维空间中找到超平面，来解决非线性分类问题。

在回归问题中，支持向量机使用支持向量回归（Support Vector Regression, SVR）来预测连续型输出变量。SVR的基本思想是找到一条拟合数据的直线或曲线，使得直线或曲线与数据点之间的误差尽可能小。

支持向量机具有许多优点，例如泛化能力强、不需要太多的训练数据、可以解决高维问题等。但是，支持向量机也有一些缺点，例如对缺失数据敏感、对参数调整敏感等。

01-10

回复 2



文云博士

在使用支持向量机时，你需要选择一些参数来调整模型的表现。这些参数包括核函数类型、核函数的参数、惩罚系数等。这些参数会对支持向量机的性能产生重大影响，因此你需要根据实际情况进行调整。

支持向量机常用的核函数包括线性核函数、多项式核函数、高斯核函数、Sigmoid核函数等。这些核函数的选择取决于数据的类型和分布情况。例如，在线性可分的数据集上，线性核函数效果较好；在非线性的数据集上，高斯核函数或多项式核函数效果较好。

01-10

回复 喜欢



海阔天空

楼主请问下，为什么令 $\|w\| \cdot b$ 等于1不会影响目标函数优化呀？另外非常感谢楼主，感觉是看过的写得最清楚的文章之一了👏👏

2019-11-18

回复 3



听风吟

这里有个数学上的推理证明，博主的说法太草率了，[SVM 白板推导|由最大间隔化目标演化的损失函数推导过程](#)

06-08

回复 1



sparking ▸ 阿泽

从分类的结果上来看确实是应该是只要能够判断和0的关系即可，但是也有可能在-1和1之间啊，这样就不符合支持向量的假设了啊

2021-03-02

回复 喜欢

[展开其他 2 条回复](#) >



Cherish

您好，我想问一下，在互补松弛条件那里，为什么不能 λa_i 和 a_i 同时等于0，感觉 $\lambda a_i = 0$ 只能推出 $g_i(x) \leq 0$ 而不能推出 < 0

2020-03-15

回复 4



一天学习三小时

分析 $\lambda_i a_i = 0$ 时应该按 λ 是否等于分析才对，也可以得出互补松弛条件

2021-07-01

回复 喜欢



111

同问

2020-04-01

回复 喜欢



machine

感觉楼主写的很棒了，但有的地方确实不太详细，甚至有错误

2020-07-15

回复 3



autodiving

哪块有错误

2021-09-01

回复 喜欢



北方半仙

个人感觉最难的部分smo算法如何优化部分没有写😓

2019-09-27

回复 2



阿泽 作者

因为怕写了，就太多了

2020-11-13

回复 喜欢



蒸汽胡

哈哈确实 很多现有的书籍都只是简单提了一句smo算法的大致思想😓

2020-11-13

回复 喜欢



六个骨头

其实用的还是挺多的，不过要是和神经网络比他就真算用的不多了。

2019-08-22

回复 2



村口烫头王师傅

不对吧，SVM作为老牌分类器.....用的不多吗？

2019-08-17

回复 2



李世博

大部分实际场景都是线性不可分，结果都得映射高维，速度慢。工业应用就不多。

但是科研教学还是很好用。

还一个问题我觉得是同样高维解释性较难，不如塞进神经网络。

SVM在大多数情况下都是使用线性核，做二分类。
多分类会遇到不可分区域，还是计算量大。

但其实我认为是最好理解的分分类器。

2021-04-15

回复 3



阿泽 作者

速度太慢了



2019-08-19

回复 7

展开其他 1 条回复 >



小怪兽

你好，想问下现在工业界用什么比较多呀😓

2019-08-15

回复 2



阿泽 作者

分类的话，决策树和神经网络比较多

2019-08-15

回复 26



小怪兽 阿泽

酱紫，感谢😓

2019-08-15

回复 1



超常规思维

机器的时代让人类的生活更加方便

2019-08-13

回复 2



machine

下标有问题吧，w和λ应该是不同的下标

2020-07-15

回复 1

[点击查看全部评论 >](#)



发布一条带图评论吧

文章被以下专栏收录



机器学习算法与自然语言处理

公号[机器学习算法与自然语言处理] 微信号yizhennotes



涂山随笔录

菩提本无树，明镜亦非台。



我在知乎学生信

与同学一起学习生物信息学

推荐阅读

【机器学习】支持向量机 SVM (非常详细)


1. 支持向量1.1 线性可分首先我们先来了解下什么是线性可分。在二维空间上，两类点被一条直线完全分开叫做线性可分。严格的数学定义是： D_0 和 D_1 是 n 维欧氏空间中的两个点集。如果存...

朱晓阳

初学者如何"一步一步"理解 SVM支持向量机


2018年8月5日更新：原文中提到的一部分视频资源已经无法访问，因此修改和删掉了一些无法访问的链接。其实，目前网上已经有大量的文献资料介绍这种机器学习的算法——支持向量机 (Support ...

咖啡萝卜丝



支持向量机 (SVM) 简介及代码实践

零独叶



SVM教程：支持向量机理解

论智